

用于轻度认知障碍诊断的群体相似约束功能脑网络建模方法

李伟凯¹, 高欣², 纪同俭³, 王政霞¹

(1. 南京航空航天大学计算机科学与技术学院, 江苏 南京 210016;

2. 上海全景医学影像诊断中心, 上海 200233;

3. 山东莒县妇幼保健院, 山东 日照 276500)

摘要: 功能脑网络为理解大脑功能激活模式及大脑信息传递结构提供了一种有效的生物标记, 如何更加有效地利用先验信息构建准确的脑网络模型尤为重要。提出了一种基于群体相似性约束的功能脑网络模型, 通过引入张量低秩约束, 利用张量的核范数, 求解一个在组内具有低秩先验的脑网络组。这种方法利用组内的相似性约束, 收缩脑网络的解空间, 从而有效地构建更优的脑网络模型。将所构建的脑网络用于轻度认知障碍的判别任务, 实验结果表明, 所提出的基于群体相似性约束的脑网络建模方法, 能够构建出更具判别性的脑网络, 并得到了与以往研究一致的显著性连边, 进一步验证了所提出方法的有效性。

关键词: 张量低秩; 大脑功能网络; 功能磁共振成像; 组约束

中图分类号: TP311.134.3

文献标识码: A

doi: 10.11959/j.issn.2096-6652.201922

Method of functional brain network modeling with group similarity constraint for mild cognitive impairment classification

LI Weikai¹, GAO Xin², JI Tongjian³, WANG Zhengxia¹

1. College of Computer Science and Technology, Nanjing University of Aeronautics and Astronautics, Nanjing 210016, China

2. Shanghai Universal Medical Imaging Diagnostic Center, Shanghai 200233, China

3. Shandong Juxian Maternal and Child Health Hospital, Rizhao 276500, China

Abstract: Functional brain network provides an effective biomarker for understanding brain activation patterns, the development of neurodegenerative diseases, and the structure of brain signaling. How to use priori information to build accurate brain network is particularly important in subsequent applications. A functional brain network construction model based on group similarity constraints was proposed. By introducing a tensor low rank constraint and using the nuclear norm of the tensor, a brain network group with a low rank prior in the group was solved. The group similarity constraints to shrink the solution space of the brain network was used, thus constructing a better functional brain network effectively. For evaluating the performance of the proposed method, the constructed brain network was adopted for the discriminative task of mild cognitive impairment. The experimental results show that the proposed functional brain network modeling method based on group similarity constraints can construct more discriminative brain network. In addition, based on the brain network constructed by the proposed method, the significant connections consistent with previous studies are obtained, and the effectiveness of the proposed method is further verified.

Key words: low-rank of tensor, functional brain network, functional magnetic resonance imaging, group constraint

收稿日期: 2019-04-04; 修回日期: 2019-05-20

通信作者: 高欣, george.ssmu@163.com; 王政霞, zxiawang@163.com

基金项目: 重庆市教委科技研究基金资助项目 (No.KJQN201800716, No.KJ175492); 重庆市科委自然科学基金资助项目 (No.2018jcyjAX0398); 上海市卫计委科研课题基金资助项目 (No.201740010)

Foundation Items: Scientific and Technological Research Program of Chongqing Municipal Education Commission (No.KJQN201800716, No.KJ175492), Natural Science Foundation Project of CQCSTC (No.2018jcyjAX0398), Scientific Research Project of Shanghai Municipal Planning Commission of Health and Family Planing (No.201740010)

1 引言

阿尔茨海默症 (Alzheimer's disease, AD) 是一种神经系统退行性疾病^[1]。最近的一项研究^[2]指出, 在 65 岁以上的人群中, AD 影响记忆、推理和沟通能力, 严重干扰人类的日常生活, 最终可导致死亡。然而, 不幸的是, 到目前为止, 仍然没有有效的手段可以治疗 AD。因此, 识别 AD 的早期症状, 延缓 AD 发病和进展的药物或行为干预非常重要。

通常, 研究者将轻度认知障碍 (mild cognitive impairment, MCI) 作为 AD 早期阶段的一个预测靶点^[3]。最近的一些统计研究发现, 每年有 10%~15% 的 MCI 患者倾向于发展为可能的 AD^[4-5]。无论是对 MCI 期还是 MCI 临床前的早期治疗都被认为是减缓 AD 进展的重要手段^[6]。因此, 对于 MCI 的诊断显得尤为重要。

作为一种时间分辨率丰富、非侵入无辐射的医学成像技术, 功能磁共振成像 (functional magnetic resonance imaging, fMRI) 技术为测量脑活动提供了一种非常有效的方法^[7-9]。然而, 考虑到跨受试者自发的大脑活动或扫描仪器的状态通常是随机且异步的, 因此, 利用 fMRI 从正常对照组中识别 MCI 患者仍然是一个严峻的挑战。相比之下, 利用二阶或者更高阶的统计信息, 功能性脑网络 (functional brain network, FBN) 能有效刻画大脑内部信息的传递方式, 通过一个整体的方式对大脑的模式进行更加深入的了解, 从而为大脑的激活模式和拓扑结构进行一个更加深入的表述, 为理解大脑以及神经退行性疾病提供一个更加稳健的生物标记。目前, 针对脑网络的研究已经成为大脑科学神经科学中的一个信息研究热点^[10-14]。此外, 大脑功能网络连接也被发现与一些神经退行性疾病 (如自闭症 (autistic spectrum disorder, ASD)^[15-16]、轻度认知障碍^[12, 17-19]、老年痴呆^[20-22]以及帕金森综合征 (Parkinsonism disease, PD) 等) 高度相关。事实上, 所有这些都在很大程度上依赖于最终估计的 FBN 的质量, 因此, 估计一个更可靠的 FBN 显得至关重要^[23]。

最近的一项综述显示, 最广泛使用的 FBN 建模方式是基于二阶统计量 (或相关性) 来刻画不同脑区或者兴趣区 (region of interest, ROI) 之间的连接^[24]的, 这些基于相关性的脑网络建模方法通常比复杂的高阶方法更加有效。因此, 本文主要关注

基于相关性的方法, 并简要回顾皮尔逊相关 (Pearson's correlation, PC)^[25]、稀疏表示 (sparse representation, SR)^[26-27]以及一些相关的变体等方法。由于数据采集时存在噪声, 因此构建的脑网络不可避免地会存在稠密的连接, 包含大量的噪声或虚假连接。一个解决办法就是引入稀疏的先验信息, 如阈值方法或 LASSO 的方法^[25]。但是, 需要注意的是, 脑网络是一个复杂的系统, 并不简单地只有稀疏性一个先验信息^[13, 28]。目前, 为了获得更有代表性的 FBN, 已经有研究提出了更好的 FBN 估计和神经疾病诊断。事实上, 它们大部分都可以在一个正则化的框架下进行解释, 这说明一个可靠的 FBN 估计模型不仅要很好地拟合数据, 而且要有效地编码大脑组织的先验知识^[29]。实践中, 常用的先验信息包括稀疏性、模块性、群稀疏性、低秩和无标度性等^[19, 25-26, 29-30]。另外, 还可以通过数据的质量^[23]以及其他先验知识^[31]构建脑网络正则项。FBN 估计模型将这些先验信息转化为相应的正则项, 从而提高了得到的 FBN 的性能和诊断的准确性。

事实上, 在人类不断进化的过程中, 大脑的结构和功能通常会趋向于具有一个相似的结构, 从而保证对信息的处理最优, 即组内的样本具有一定的相似信息^[31]。然而, 目前主流的脑网络建模方式通常都是针对单个脑网络进行估计, 因此会损失一定的组相似信息。实际上, 这种组内的相似性约束能够更有效地指导大脑功能网络进行更精确的估计。因此, 本文试图通过引入组内的相似性约束, 利用正则化技术将组约束信息嵌入现有的脑网络模型中, 从而利用组约束信息构建更加精确、稳定的脑网络。

目前主流的脑网络建模框架都是基于矩阵的正则化约束框架, 然而, 这种基于矩阵的方式很难嵌入脑网络在组间的相似性。因此, 为了更好地刻画组内信息, 本文将现有的矩阵正则化模型扩展到张量正则化模型。另外, 考虑到实际上相似性约束转化为数学形式可以表示为互表达的方式, 而这种互表达可以进一步通过低秩性先验信息来逼近, 因此, 本文通过张量的低秩正则化约束引入脑网络的组相似性约束。然而, 低秩性约束的求解是一个非凸且 NP 难问题, 因此, 可以利用张量低秩正则项的上限张量的核范数将其转化为一个凸问题进行求解。另外, 还可以利用 PARAFAC (平行因子) 分解通过求解张量的特征值之和来求解核范数^[32],

从而通过对核范数进行惩罚得到一个有效的具有低秩特性的张量解，通过这种方式即可构建一个具有组内相似性约束的功能脑网络。相比于传统的脑网络建模方法构建的脑网络，本文方法所构建的脑网络嵌入了更多的有效信息，因此能够得到更加稳定的脑网络，从而提供更稳定的生物标记。

最后，本文将张量核范数正则项嵌入传统的偏相关脑网络以及全相关脑网络建模中，进行一个简单的验证。另外，利用轻度认知障碍的早期诊断精度作为度量来描述脑网络的性能，最后发现所提出的方法得到了更好的诊断精度。测试数据来源于ADNI (Alzheimer's disease neuroimaging initiative) 数据集。本文模型具有以下优点。

① 与传统的针对单个被试单独构建脑网络的出发点不同，本文提出了一种基于张量形式的脑网络建模方式，通过张量的形式，为群组整体同时构建脑网络，并通过张量正则化技术，构建一个具有组内相似性约束的脑网络。

② 本文将组内相似性约束转化为张量的低秩正则项，嵌入基于张量形式的脑网络建模，并进一步松弛成为张量的核范数正则项，并设计了相应的优化求解算法，得到了具有组内相似性的约束。

③ 将基于本文方法所构建的脑网络应用到对轻度认知障碍的分类预测任务中，实验结果发现，引入组内相似性约束后，能够得到更加具有判别性的脑网络，进一步分析发现，最具有判别性的方法具有生理上的可解释性。

④ 本文提供了一个基于组内相似性约束的模块，能够很容易嵌入现有的脑网络建模框架中。另外，为了验证这个扩展性的有效性，本文将PC和SR作为基准试验进行测试，实验结果表明，本文所提出的方法能够有效地提升现有方法所构建的脑网络对于MCI分类的精度。

2 脑网络建模方法

人脑系统作为目前自然界中最复杂的系统之一，研究人员利用组学数据对其进行了刻画和分析，事实上，这种组学数据本身就体现了人脑连接的特点。人脑中有大量的神经元细胞，这些神经元细胞通过海量的突触互相连接，形成了一个高度有效的信息传递和处理网络。大量研究表明，大脑对信息和认知进行处理的基础就是脑网络中的拓扑连接。近年来，随着对大脑连接体系理解的进一步

加深，为有效地加强学术界对脑网络连接的理解和重视，人脑连接组 (human connectome) 这一概念在2005年被Olaf Sporns首次提出^[33]。目前，脑网络连接可以从微观 (神经元)、中观 (神经集群) 以及宏观 (大脑脑区) 3个不同的尺度来刻画不同水平下的大脑连接拓扑，从而有效挖掘大脑的连接模式。由于目前数据采集设备的分辨率不足，现有的针对脑网络组学的研究通常是基于一个宏观尺度 (即脑区或体素水平) 的脑网络研究，通过脑电、脑磁、fMRI、弥散张量成像 (diffusion tensor imaging, DTI) 等技术，建立脑区之间的联系或者体素之间的连接。这里对基于fMRI数据的宏观尺度的脑网络建模方法进行简单介绍。

宏观尺度的脑网络首先需要获取宏观尺度的BOLD (blood oxygenation level dependent) 信号，一般采用ROI或者脑区的平均信号。目前，一项脑网络的综述研究^[34]指出，基于二阶统计量的全相关的脑网络建模方式^[25]比其他复杂的脑网络方式更加稳定。此外，其他一些复杂的脑网络建模方式 (从简单到最复杂) 有偏相关模型^[35]、贝叶斯网络模型、结构方程模型^[36]、动态因果模型^[37]。事实上，大部分的脑网络建模模型都可以抽象为对于生理特征以及数据统计关系之间的建模，而这些模型都是在统计性能、生理特征表示以及计算鲁棒性之间的一种平衡和折中。比如基于全相关的PC脑网络建模模型，能够有效刻画脑区之间的相关关系，计算性能高效。然而，这种方式无法有效地在模型中嵌入脑网络中的生理先验信息，因此扩展性不足。动态因果模型虽然能够对大脑信息传递的生理信息进行刻画，然而其计算复杂度非常高，很难对大规模的网络进行计算，因此只能针对少量节点的网络进行建模。这些方法通常只针对有特点的先验信息或者统计信息进行建模，很难进行扩展，因此需要一种更易扩展的框架对脑网络进行建模。由于正则化框架在机器学习中可以很好地通过引入数据拟合项以及正则项对先验信息及物理假设进行建模，因此正则化技术也开始应用于脑网络建模中，对脑网络进行构建和约束，从而引入统计假设以及生物先验信息。文献[38]发现，这种正则化框架构建脑网络的方式为构建的脑网络嵌入先验信息提供了一种非常高效的平台，从而使得所构建的脑网络具有更好的生物可解释性，并且该框架下大量的优化工具包能实现非常高效的求解。由于本文更多的是对

组内约束的验证,且考虑到二阶统计量的脑网络的稳定性,因此本文采用基于二阶统计量的最常用的相关性(PC 以及偏序相关)的脑网络建模方法作为基准方法,下面分别进行简要介绍。

2.1 基于 PC 的脑网络建模

首先获取配准好的 fMRI 数据矩阵 $\mathbf{X}$, 其中 $\mathbf{X} = [x_1, x_2, \dots, x_n] \in R^{t \times n}$ 代表利用每个被试 fMRI 数据所提取的脑区 BOLD 信号。 $\mathbf{X}$ 的每一列代表对应脑区的相应的 BOLD 信号序列。基于 PC 的脑网络模型是最常用的构建脑网络方式^[34], 表示如下。

$$W_{ij} = \frac{(x_i - \bar{x}_i)^T (x_j - \bar{x}_j)}{\sqrt{(x_i - \bar{x}_i)^T (x_i - \bar{x}_i)} \sqrt{(x_j - \bar{x}_j)^T (x_j - \bar{x}_j)}}$$

其中, $x_i \in R^t$ 来自第 i 个脑区的 BOLD 信号, t 是时间点的数量, $\bar{x}_i \in R^t$ 表示所有 x_i 所对应的均值, $i=1, 2, \dots, n$, n 是被试的数量。其中, $x_i - \bar{x}_i$ 可以看作 x_i 的归一化方式。

由于数据在采集过程中会受到噪声的影响, 基于 PC 构建的脑网络通常会存在大量的虚假连接, 因此基于 PC 构建的脑网络通常需要阈值化处理, 从而滤除相应的虚假连接和弱连接。这种阈值化处理方法(简称为“PC threshold”)可以表示如下。

$$W_{ij}^{(new)} = \begin{cases} W_{ij}, & W_{ij} > threshold \\ 0, & \text{其他} \end{cases}$$

其中, $W_{ij}^{(new)}$ 定义了节点 i 和节点 j 在阈值化处理后保留的连接。

2.2 基于稀疏表示的脑网络建模

基于 PC 的方法是对全相关进行刻画的, 因此其很难解决不同节点互相影响的混淆问题, 而基于偏序相关的方法可以通过逼近全相关(即 PC)的逆的形式来解决这个问题^[39]。然而, 由于这种方式需要对相关矩阵的逆进行求解, 往往会得到一个奇异解, 因而常用的解决方式是利用稀疏表示(SR)来解决偏序相关求解退化的问题。目前基于 SR 的偏序相关脑网络的研究也非常广泛^[40]。SR 的模型表示如下。

$$\min_W \sum_{i=1}^n \|x_i - \sum_{j \neq i} W_{ij} x_j\|^2 + \lambda \sum_{j \neq i} \|W_{ij}\|$$

其矩阵形式为

$$\begin{aligned} \min_W & \|\mathbf{X} - \mathbf{X}\mathbf{W}\|_F^2 + \lambda \|\mathbf{W}\| \\ \text{s.t. } & W_{ii} = 0, \forall i = 1, \dots, n \end{aligned}$$

其中, 数据中的拟合项 $\|\mathbf{X} - \mathbf{X}\mathbf{W}\|_F^2$ 对不同脑区之间的偏序相关统计关系进行刻画, 上式中的 l_1 -范数正则项 ($\|\mathbf{W}\|$) 刻画了大脑的稀疏性先验信息, 为得到脑网络的稳定解起了关键作用。 λ 为正则化参数, 用于控制所构建脑网络的稀疏程度。

2.3 基于正则化框架的脑网络建模

事实上, 现有的脑网络建模框架都可以总结到一个正则化框架中。正则化框架是贝叶斯概率统计模型中提出的概念, 通过拉普拉斯变换, 将约束信息转化为正则项, 实现对有约束模型的求解, 这种方式能够有效地使约束的先验信息在结果中得到表达。通过对常用的脑网络模型进行总结, 发现这些模型都可以看作是在生物可解释性、计算性能以及统计鲁棒性之间寻求一种平衡。这样在数据和先验知识之间寻求平衡, 就可以看成是对脑网络的约束, 因此可以通过拉普拉斯变换, 将约束项引入正则化框架中, 并通过正则项的概念, 将一些先验信息转换为模型的约束引入脑网络的建模中, 正则化框架表示如下。

$$\min_W f(\mathbf{X}, \mathbf{W}) + \lambda R(\mathbf{W}), \text{ s.t. } \mathbf{W} \in \Delta$$

其中, $f(\mathbf{X}, \mathbf{W})$ 为数据拟合项, 这一项的主要功能为获取数据之间的统计信息(比如利用相关系数或者其他的一些统计模型), $R(\mathbf{W})$ 则是一个正则项, 这一项可以通过增加对 $\mathbf{W}$ 的约束来引入脑网络的一些先验信息(稀疏性、模块性等)。当然, 还有一些其他的约束(比如对称或者半正定)会通过给定约束 Δ 来进一步收缩脑网络 $\mathbf{W}$ 的解空间, 从而得到更好的脑网络。

3 基于群体相似性约束的脑网络建模方法

目前的脑网络建模方法通常都是针对单个被试构建脑网络, 因此很难引入组内脑网络之间的联系。本文试图通过张量模型, 将合适的张量正则项嵌入脑网络构建模型中, 从而引入这种组内的约束信息, 并期望得到更加具有辨识性的脑网络。

3.1 模型假设

在人类的进化过程中, 大脑不同区域之间的联系存在相似性。然而, 现有的方法很少对这种群体内的相似性约束进行建模, 指导脑网络的构建。事实上, 这种相似性在网络构建的过程中能够提供非常有效的监督信息, 因此可以利用这种相似性来约束脑

网络的构建。组内脑网络间的相似约束如图1所示。




图1 组内脑网络间的相似约束

3.2 模型构建

传统的矩阵正则化建模方式无法有效地刻画组内的约束信息，因此，本文试图利用基于张量建模脑网络有效地引入组约束信息。利用三维张量有效地扩充样本的维度，从而嵌入组内的约束信息，进而将基于张量的脑网络建模方式形式化表示如下。

$$\min_{\mathbf{W}} \sum_{i=1}^n f(\mathbf{X}^{(i)}, \mathbf{W}^{(i)}) - \lambda R(\mathbf{W})$$

其中， $\mathbf{X} \in \mathbb{R}^{N \times T \times n}$ 代表输入的数据， N 代表脑区的数量， T 代表时间点， n 代表被试的数量， $\mathbf{X}^{(i)}$ 代表第 i 个被试的数据。 $\mathbf{W} \in \mathbb{R}^{N \times N \times n}$ 代表所构建的群组脑网络， $\mathbf{W}^{(i)}$ 代表第 i 个被试所构建的脑网络。

显然， $\mathbf{X}$ 、 $\mathbf{W}$ 是三维张量， $\sum_{i=1}^n f(\mathbf{X}^{(i)}, \mathbf{W}^{(i)})$ 是数据拟合项， $\lambda R(\mathbf{W})$ 是需要引入的张量正则项。

为了引入这种组内相似的脑网络结构先验信息，本文将脑网络之间的相似性约束抽象成为一个张量低秩的约束。因此，将张量的低秩正则项引入脑网络的构建中，得到如下模型。

$$\min_{\mathbf{W}} \sum_{i=1}^n f(\mathbf{X}^{(i)}, \mathbf{W}^{(i)}) + \lambda R(\mathbf{W})_{\text{lowrank}}$$

然而，低秩正则项的求解显然是一个 NP 难问题，为了方便求解，利用低秩正则项的上确界核范数来逼近低秩正则项。

$$\min_{\mathbf{W}} \sum_{i=1}^n f(\mathbf{X}^{(i)}, \mathbf{W}^{(i)}) + \lambda \|\mathbf{W}\|_*$$

为了验证模型的有效性，把传统的 PC 方法和 SR 方法引入模型，并得到了基于 PC 模型的张量正则化模型（简称为“PC+LR”），表示如下。

$$\min_{\mathbf{W}} \sum_{i=1}^n (\mathbf{W}^{(i)} - \mathbf{X}^{(i)} \mathbf{X}^{(i)\top}) + \lambda \|\mathbf{W}\|_*$$

基于 SR 模型的张量正则化模型（简称为

“SR+LR”）表示如下。

$$\min_{\mathbf{W}} \sum_{i=1}^n (\mathbf{W}^{(i)} - \mathbf{X}^{(i)} \mathbf{W}^{(i)}) + \lambda \|\mathbf{W}\|_*$$

需要注意的是，本文仅将核范数正则项作为一个示例，试图对基于张量的正则化框架的有效性进行验证。事实上，可以根据相应的设计进一步引入其他的约束，如 $l_{2,1}$ -范数正则项等。

3.3 模型求解

考虑到模型本身是一个凸的不可微的优化问题，借鉴传统正则化框架下对脑网络模型的求解。本文对目标函数的拟合项和正则项分别进行求解。具体地，本文所提出的 PC+LR 以及 SR+LR 模型较 PC 和 SR 模型来说增加了一个张量核范数正则项约束。与 l_1 -范数正则项相同，张量核范数为一个不可导的凸函数，目前针对该类不可导凸函数问题的求解已有大量的研究工作^[41-43]。考虑到近端算子方法的快速求解能力，本文采用近端算子方法对目标函数进行优化求解，具体如下。

先考虑目标中的数据拟合项 $f(\mathbf{X}, \mathbf{W}) = \|\mathbf{W} - \mathbf{X}^T \mathbf{X}\|_F^2$ ，其导数为 $\nabla_{\mathbf{W}} f(\mathbf{X}, \mathbf{W}) = 2(\mathbf{W} - \mathbf{X}^T \mathbf{X})$ ，因此，通过梯度下降的方式求解。

$$\mathbf{W}_k = \mathbf{W}_{k-1} - \alpha_k \nabla f(\mathbf{X}, \mathbf{W}_{k-1})$$

对于张量核范数正则项的求解，是在二维张量中，通过对奇异值之和进行约束，得到一个相应的低秩的矩阵。扩展到高维张量的核范数约束中，同样利用类似的方式，实现对张量核范数问题的求解，从而得到一个具有低秩特性的三阶张量。在这里，利用 PARAFAC 分解获取特征值元素之和，并对其进行约束，从而限制张量的秩。具体地，PARAFAC 分解将一个张量 $\chi \in \mathbb{R}^{I_1 \times I_2 \times I_3}$ 分解为 n 个秩 1 张量的和，其表达式如下。

$$\chi \approx \hat{\chi} = \sum_{r=1}^n \chi_r = \sum_{r=1}^n \lambda_r \alpha_r^{(1)} \alpha_r^{(2)} \alpha_r^{(3)}$$

其中， $\hat{\chi}$ 是一个对张量 χ 逼近的秩 n (Kruskal 秩) 的张量， $\chi_r \in \mathbb{R}^{I_1 \times I_2 \times I_3}$ 是一个秩 1 张量， $\alpha_r^{(1)} \alpha_r^{(2)} \alpha_r^{(3)}$ 是一个单位范数空间的向量， λ_r 为对应的特征值，其中， $\hat{\chi}$ 可以分解为如下形式。

$$\hat{\chi}_{ijk} = \sum_{r=1}^R \lambda_r \alpha_{ir}^{(1)} \alpha_{jr}^{(2)} \alpha_{kr}^{(3)}$$

设定 $\|\chi - \hat{\chi}\|_F^2 < 10^{-5}$ ，对其进行分解，则正则项可以被下面的近端算子逼近。

$$\text{prox}_{\lambda\|\cdot\|_*}(W) = \sum_{r=1}^R \max(\lambda_r - \lambda, 0) \alpha_{lr}^{(1)} \alpha_{jr}^{(2)} \alpha_{kr}^{(3)}$$

其中, $R = \min(I_1, I_2, I_3)$ 。最后, 在对拟合项进行梯度下降计算后, 利用近端算子 $\text{prox}_{\lambda\|\cdot\|_*}$ 对解进行逼近, 从而构建出具有低秩特性的脑网络, 进而得到具有组相似性的解, 总结见算法 1。

算法 1 基于低秩组约束的脑网络构建算法

输入 X, λ

输出 W

初始化 W

while not converged

$W_{k+1} = \text{gradient}(W)$;

$W_{k+1} = \text{prox}_{\lambda\|\cdot\|_*}(W_k)$;

end

4 实验

为了验证方法的有效性, 本文利用公开的阿尔茨海默症神经影像 ADNI 数据集进行验证和分析^[44]。ADNI 数据集于 2003 年由美国国家老龄化研究所、美国国家生物医学成像与生物工程研究所、美国食品药品监督管理局, 以及一些私营制药公司和非盈利性组织发起成立。ADNI 最初的目标是定义用于临床试验的生物标志物, 并确定测量 AD 疗法治疗效果的最佳方法。

4.1 数据预处理

本次实验采取了与之前研究相同的数据^[45], 共有 137 名参与者, 其中 68 名 MCI 被试、69 名 NC 被试。扫描参数如下: TR/TE = 3000/30 mm, 旋转角为 80°, 图像大小为 64×64, 有 48 层共 140 个时间点, 每个体素的厚度为 3.3 mm。预处理利用 SPM8 toolbox 和 DPARSFA (version 2.2)^[46] 工具包进行标准的预处理。对 fMRI 数据的预处理流程包括前 10 个时间点的移除、时间层矫正、配准、空间标准化、空间平滑、时间失谐、回归协变量以及滤波。为了减轻头部运动的影响和伪影, 遵循之前的工作^[47-48] 计算了 fMRI 每个时间点的帧位移 (FD), 并在后续的分析中排除了超过 2.5 min (50 帧) 数据的 FD>0.5 的被试^[49]。最后利用 AAL (anatomical automatic labeling) 图谱^[50], 将预处理的数据划分到 116 ROIs, 并最终得到了数据矩阵 $X \in \mathbf{R}^{137 \times 116}$ 。可参考文献^[45] 了解更多的预处理细节。

4.2 试验设置

为了验证所提出张量低秩正则项对脑网络建

模的效果, 本文将 PC 以及 SR 作为基准方法进行比较, 分别用 PC、PR+LR、SR、SR+LR 对获取的数据构建脑网络模型。

脑网络模型构建完成后, 需要对其进行评判, 事实上, 目前还没有一个统一的评判标准。因此, 本文选择一种最常用的度量脑网络性能的方式, 即将构建的脑网络对于神经性疾病的预测和分类作为对脑网络度量的指标。另外, 考虑到脑网络中连接数目过多, 为了保持评价结果具有良好的泛化能力, 需要进行进一步的特征提取。为了避免特征提取对结果造成混淆效应, 选取最简单的 ttest 作为特征提取的方式, 选取 p 值小于 0.01 的连接作为特征输入分类器进行训练。同样, 为了避免分类器的选取造成混淆效应, 采用最常用的线性核支持向量机 (support vector machine, SVM) 作为分类器。最后, 考虑到医学样本数量不足, 使用严格的交叉验证来计算所得到的精度, 作为所构建脑网络最后的性能评价。因此, 实验流程一般分为两步: 第一步, 通过不同的参数训练不同的脑网络; 第二步, 对构建的脑网络进行特征提取, 并利用交叉验证计算构建脑网络的性能。

为了对所构建的模型进行验证, 考虑到一个小样本问题, 本文利用留一法进行交叉验证, 对所提出的脑网络建模方法进行评估。具体地, 构建了内、外两层循环, 在每次外层循环中, 留一个被试数据作为测试集, 将其余被试数据用于模型训练。为了选择参数, 在内层循环中留一个被试数据作为验证集, 并在内层循环中选择每次最佳的参数, 对整体训练组进行重新训练。对于参数的选择, 本文利用了网格搜索策略, 稀疏以及低秩正则化的超参数的取值范围为 $[2^{-5}, 2^{-4}, \dots, 2^0, \dots, 2^4, 2^5]$, 基于 PC 的阈值方法选取的稀疏度为 $[5\%, 10\%, \dots, 95\%, 100\%]$, 其中 90% 代表了 10% 的虚假连接或者弱的连接被去除。

对于构建脑网络的评判标准, 本文采用最常见的评判方式, 将对于 MCI 诊断预测的分类结果的精度 (accuracy)、敏感性 (sensitivity) 以及特异性 (specificity) 作为衡量脑网络优劣的标准, 其数学定义如下。

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + TN + FN}$$

$$\text{Sensitivity} = \frac{TP}{TP + FN}$$

$$Specificity = \frac{TN}{TN + FP}$$

其中, TP 、 TN 、 FP 以及 FN 分别代表真阳性、真阴性、假阳性和假阴性的数量。

4.3 试验结果

首先在图2中给出不同方法所构建的脑网络的邻接矩阵。




图2 不同方法构建的脑网络邻接矩阵

由图2可以发现, 基于低秩的方法并没有对原有的脑网络结构做太大的改动。因此, 这种组约束信息能够有效地去除一些虚假链接。为了验证模型的有效性, 仍然将精度、敏感性和特异性作为脑网络的评价指标, 其在 ADNI 数据集上的结果见表1。

表1 在 ADNI 数据集上不同方法在 MCI 分类问题中的效果

方法	精度	敏感性	特异性
PC	68.61	71.01	66.17
PC+LR	75.91	79.71	72.05
SR	74.45	78.26	70.59
SR+LR	80.29	86.95	73.52

4.4 结果分析

通过上述实验结果可以发现, 组约束的引入能够有效地提升基线方法 (PC 以及 SR) 在 MCI 分类任务上的有效性, 这正是因为本文所提出的方法能够有效地嵌入这种组内相似性约束信息, 从而有效地提升脑网络对疾病分类和诊断的最终精度和性能。

此外, 对不同方法构建的网络的模块性、全局效率以及层级系数进行了分析, 从而进一步分析构

建的脑网络, 结果如图3所示, 属性值利用 Gretna 工具包计算, 图中的误差限代表标准差。




图3 不同方法构建的脑网络的模块性、全局效率以及层级系数

由图3可以发现, 引入组内相似约束信息可以有效地提升基准方法的脑网络模块性、全局效率以及层级系数等图论的拓扑属性。这些属性说明组内约束信息构建的脑网络能够有效地增强高度的小世界属性, 这个结果也与目前大脑的研究相吻合, 进一步说明了所提出方法的有效性和合理性。

对大脑运行机制以及模式的探索是目前极其重要的研究之一, 而对于脑网络的分析和研究, 是对大脑进行深入分析和建模的重要手段之一, 而脑网络研究的一个重要基础是对脑网络的准确构建。本文利用正则化框架, 利用张量的核范数约束, 引入脑网络的组内相似性约束, 试图构建更加准确的脑网络, 从而对脑网络进行构建和分析研究。但大脑本身是极其复杂的, 这给构建和分析带来了很大的挑战。虽然本文对脑网络的建模进行了改进, 并取得了一定的进展, 但仍然存在很多不足之处。一些待解决的问题和未来需要进一步进行的工作主要包括以下两个方面。

① 目前的脑网络并没有很好的评判标准, 因此, 本文只能利用最常见的对脑网络进行评判和分析的检验方法, 将构建的脑网络应用于一些神经性疾病的诊断, 然后将诊断的精度作为评判脑网络好坏的标准。下一步的工作是对脑网络进行进一步的

研究,希望可以找到更好的脑网络评价的“精标准”。

② 本文通过张量正则化框架将现有的基于个体水平的脑网络构建扩展到组内水平的脑网络构建,有效地引入了组内约束性信息,如本文所采用的组内相似性约束。然而,大脑是一个极其复杂的系统,如何嵌入对大脑网络的先验信息仍然是一个挑战。

5 结束语

人脑是一个极其复杂烦琐的系统,事实上,目前人类对大脑的认知和了解仍然是微不足道的,因此,如何更好地刻画大脑仍然是一个具有挑战性和有意义的课题。在人类的进化过程中,大脑的拓扑结构和联系会趋于一种相似性的结构,而这种相似性事实上就可以视为一种自监督信息,可以更好地引导脑网络的构建和分析。另外,对脑网络的研究一方面为疾病诊断提供了信息的生物标记,另一方面能为新一代人工智能提供有效的指导和借鉴^[51-52]。因此,对脑网络的研究具有重要的意义。本文利用张量正则化,将核范数正则项嵌入脑网络构建模型中,可以构建一个具有组内相似性约束的脑网络。在优化过程中,利用PARAFAC分解得到了张量的特征值,计算张量的核范数。最后,将构建的脑网络用于对MCI的分类,实验发现,组约束的引入能够有效地提升原始模型的判别性。另外,本文想要说明的是,组约束信息不仅仅包括相似性约束,相似性约束也不仅仅可以通过核范数来近似。本文仅是一个分析组约束的有效性的验证性试验,因此,本文所提出的模型仍然存在一定的改进空间,比如对于模型图谱的选择、样本量的扩充,以及正则化参数的优化。对于低秩的逼近以及如何更好地刻画脑网络组内的约束信息仍需进一步的研究。

参考文献:


- [1] GAUGLER J, JAMES B, JOHNSON T, et al. 2016 Alzheimer's disease facts and figures[J]. *Alzheimers & Dementia*, 2016, 12 (4): 459-509.
- [2] BAIN L J, JEDRZIEWSKIA K, MORRISON-BOGORAD M, et al. Healthy brain aging: a meeting report from the Sylvan M. Cohen annual retreat of the University of Pennsylvania Institute on Aging[J]. *Alzheimers & Dementia*, 2008, 4(6): 443-446.
- [3] WEE C Y, YAPP-T, ZHANG D Q, et al. Identification of MCI individuals using structural and functional connectivity networks[J]. *NeuroImage*, 2012, 59 (3): 2045-2056.
- [4] GRUNDMAN M, PETERSEN R C, FERRIS S H, et al. Mild cognitive impairment can be distinguished from Alzheimer disease and normal aging for clinical trials[J]. *Archives of Neurology*, 2004, 61(1): 59.
- [5] MISRA C, FAN Y, DAVATZIKOS C. Baseline and longitudinal patterns of brain atrophy in MCI patients, and their use in prediction of short-term conversion to AD: results from ADNI[J]. *Alzheimers & Dementia*, 2009, 44(4): 1415-1422.
- [6] Alzheimer's Association. 2017 Alzheimer's disease facts and figures[R]. 2017.
- [7] BRUNETTI M, BELARDINELLI P, GRATTA C D, et al. Human brain activation elicited by the localization of sounds delivering at attended or unattended positions: an fMRI/MEG study[J]. *Cognitive Processing*, 2006, 7(1): 116-117.
- [8] LEE J H, DURAND R, GRADINARU V, et al. Global and local fMRI signals driven by neurons defined optogenetically by type and wiring[J]. *Nature*, 2010, 465(7299): 788-792.
- [9] KEVIN W, DOUG W, MATTHIAS S, et al. Correspondence of visual evoked potentials with FMRI signals in human visual cortex[J]. *Brain Topography*, 2008, 21(2): 86-92.
- [10] ROSAM J, PORTUGAL L, HAHNT, et al. Sparse network-based models for patient classification using fMRI[J]. *NeuroImage*, 2015, 105(3): 493-506.
- [11] STAM C J. Modern network science of neurological disorders[J]. *Nature Reviews Neuroscience*, 2014, 15(10): 683-695.
- [12] WEE C Y, YAP P T, ZHANG D Q, et al. Identification of MCI individuals using structural and functional connectivity networks[J]. *NeuroImage*, 2012, 59(3): 2045-2056.
- [13] SPORNS O. Networks of the brain[J]. *General*, 2011.
- [14] SMITH S M, MILLER K L, SALIMIK G, et al. Network modelling methods for fMRI[J]. *NeuroImage*, 2011, 54(2): 875-891.
- [15] GOTTS S J, SIMMONS W K, MILBURY L A, et al. Fractionation of social brain circuits in autism spectrum disorders[J]. *Brain: A Journal of Neurology*, 2012, 135(9): 2711-2725.
- [16] THEIJE C G M D, WU J B, SILVA S L D, et al. Pathways underlying the gut-to-brain connection in autism spectrum disorders as future targets for disease management[J]. *European Journal of Pharmacology*, 2011, S1(9): 70-80.
- [17] FAN Y, BROWNDYKE J N. MCI diagnosis via manifold based classification of functional brain networks[J]. *Alzheimers & Dementia*, 2010, 6(6): 16.
- [18] WEE C Y, YAP P T, ZHANG D Q, et al. Group-constrained sparse fMRI connectivity modeling for mild cognitive impairment identification[J]. *Brain Structure & Function*, 2014, 219(2): 641-656.
- [19] YU R, ZHANG H, AN L, et al. Correlation-weighted sparse group representation for brain network construction in MCI classification[M]. Springer International Publishing, 2016.
- [20] LIU F, WEE C Y, CHEN H, et al. Inter-modality relationship constrained multi-task feature selection for AD/MCI classification[C]// *Miccai International Conference on Medical Image Computing & Computer-assisted Intervention*, 2012:308-315.
- [21] SUPEKAR K, MENON V, RUBIN D, et al. Network analysis of intrinsic functional brain connectivity in Alzheimer's disease[J]. *PloS Computational Biology*, 2008, 4(6): 1-11.
- [22] HUANG S, LI J, SUN L, et al. Learning brain connectivity of Alzheimer's disease from neuroimaging data[C]// *Conference on Neural Information Processing Systems*. 2009:808-816.
- [23] LI W K, QIAO L S, ZHANG L M, et al. Functional brain network estimation with time series self-scrubbing[J]. *IEEE Journal of Biomedical and Health Informatics*, 2019, 99: 1.
- [24] SMITH S M, MILLER K L, SALIMI K G, et al. Network modelling methods for FMRI[J]. *NeuroImage*, 2011, 54(2): 875-891.
- [25] LI W, WANG Z, ZHANG L, et al. Remodeling Pearson's correlation for functional brain network estimation and autism spectrum disorder identification[J]. *Frontiers in Neuroinformatics*, 2017, 11: 55.
- [26] LEE H, LEE D S, KANG H, et al. Sparse brain network recovery

- under compressed sensing[J]. IEEE Transactions on Medical Imaging, 2011, 30(5): 1154-1165.
- [27] ZHOU L, WANG L, OGUNBONA P. Discriminative sparse inverse covariance matrix: application in brain functional network classification[C]// IEEE Conference on Computer Vision and Pattern Recognition, 2014:3097-3104.
- [28] SPORNS O, TONONI G, KÖTTER R. The human connectome: a structural description of the human brain[J]. Plos Computational Biology, 2005, 1(4): 42.
- [29] QIAO L, ZHANG H, KIM M, et al. Estimating functional brain networks by incorporating a modularity prior[J]. NeuroImage, 2016, (141): 399-407.
- [30] WEE C Y, YAP P T, SHEN D. Diagnosis of autism spectrum disorders using temporally distinct resting-state functional connectivity networks[J]. CNS Neuroscience & Therapeutics, 2016, 22(3).
- [31] LI W, ZHANG L, QIAO L, et al. Towards a better estimation of functional brain network for mild cognitive impairment identification: a transfer learning view[J]. bioRxiv, 2019: 684-779.
- [32] LIU X, BOURENNANE S, FOSSATI C. Denoising of hyperspectral images using the PARAFAC model and statistical performance analysis[J]. IEEE Transactions on Geoscience & Remote Sensing, 2012, 50(10): 3717-3724.
- [33] SPORNS O, TONONI G, KÖTTER R. The human connectome: a structural description of the human brain[J]. PloS Computational Biology, 2005, 1(4): 42.
- [34] SMITH S M, VIDAURRE D, BECKMANN C F, et al. Functional connectomics from resting-state fMRI[J]. Trends in Cognitive Sciences, 2013, 17(12): 666-682.
- [35] FRIEDMAN J, HASTIE T, TIBSHIRANI R. Sparse inverse covariance estimation with the graphical lasso[J]. Biostatistics, 2008, 9(3): 432.
- [36] HORN A, OSTWALD D, REISERT M, et al. The structural-functional connectome and the default mode network of the human brain[J]. NeuroImage, 2014, 102: 142-151.
- [37] FRISTON K J, KAHAN J, BISWAL B, et al. A DCM for resting state fMRI[J]. NeuroImage, 2013, 94(100): 396.
- [38] QIAO L, ZHANG H, KIM M, et al. Estimating functional brain networks by incorporating a modularity prior[J]. NeuroImage, 2016, 141: 399.
- [39] MARDIA K V, KENT J T, BIBBY J M. Multivariate analysis[J]. Mathematical Gazette, 1979, 37(1): 123-131.
- [40] LEE H, DONG S L, KANG H, et al. Sparse brain network recovery under compressed sensing[J]. IEEE Transactions on Medical Imaging, 2011, 30(5): 1154-1165.
- [41] DONOHO D L, ELAD M. Optimally sparse representation in general (nonorthogonal) dictionaries via ℓ_1 [J]. Proceedings of the National Academy of Sciences, 2003, 100(5): 2197-2202.
- [42] MEINSHAUSEN N, BÜHLMANN P. High-dimensional graphs and variable selection with the Lasso[J]. Annals of Statistics, 2006, 34(3): 1436-1462.
- [43] TOMIOKA R, SUGIYAMA M. Dual augmented Lagrangian method for efficient sparse reconstruction[J]. IEEE Signal Processing Letters, 2009, 16(12): 1067-1070.
- [44] JACK C R, BERNSTEIN M A, FOX N C, et al. The Alzheimer's disease neuroimaging initiative (ADNI): MRI methods[J]. Journal of Magnetic Resonance Imaging, 2010, 27(4): 685-691.
- [45] ZHOU Y Y, QIAO L S, LI W K, et al. Simultaneous estimation of low- and high-order functional connectivity for identifying mild cognitive impairment[J]. Frontiers in Neuroinformatics, 2018, 12: 3.
- [46] YAN C G, ZANG Y F. DPARSF: a MATLAB toolbox for "pipeline" data analysis of resting-state fMRI[J]. Frontiers in Systems Neuroscience, 2010, 4(13): 13.
- [47] CHEN X, ZHANG H, GAO Y, et al. High-order resting-state functional connectivity network for MCI classification[J]. Human Brain Mapping, 2016, 37(9): 3282-3296.
- [48] CHEN X, ZHANG H, ZHANG L, et al. Extraction of dynamic functional connectivity from brain grey matter and white matter for MCI classification[J]. Human Brain Mapping, 2017, 38(10): 5019.
- [49] POWER J D, BARNES K A, SNYDER A Z, et al. Spurious but systematic correlations in functional connectivity MRI networks arise from subject motion[J]. NeuroImage, 2012, 5(3): 2142-2154.
- [50] TZOURIOU N, LANDEAU B, PAPATHANASSIOU D, et al. Automated anatomical labeling of activations in SPM using a macroscopic anatomical parcellation of the MNI MRI single-subject brain[J]. NeuroImage, 2002, 15(1): 273-289.
- [51] 郑南宁. 人工智能新时代[J]. 智能科学与技术学报, 2019, 1(1): 1-3.
- [52] ZHENG N N. The new era of artificial intelligence[J]. Chinese Journal of Intelligent Science and Technology, 2019, 1(1): 1-3.
- 张钊. 人工智能进入后深度学习时代[J]. 智能科学与技术学报, 2019, 1(1): 4-6.
- ZHANG B. Artificial intelligence is entering the post deep-learning era[J]. Chinese Journal of Intelligent Science and Technology, 2019, 1(1): 4-6.

[作者简介]



李伟凯（1994—），男，山东日照人，南京航空航天大学在读博士生，主要研究方向为医学图像处理、脑网络构建与分析。



高欣（1975—），男，北京人，博士，副主任医师，上海市医学会结核病学专科分会委员、上海市中西医结合学会影像医学分会委员，主要研究方向为胸腹部肿瘤综合影像诊断、中枢神经系统磁共振诊断。



纪同俭（1972—），男，山东日照人，主治医师，现任莒县妇幼保健计划生育服务中心理事长、莒县医学会秘书长、日照市医师协会理事，主要研究方向为普外科。



王政霞（1977—），女，山东日照人，博士，重庆交通大学教授、硕士生导师，主要研究方向为机器学习、图像处理及医学影像诊断。